

Numerical Computation of Eigenvalues

En caso de encontrar un error o posible mejora, no dude en mencionarlo en clases o por email. ¡Gracias!

(S)cientific (C)omputing (T)eam
ILI-286 DI-UTFSM Chile

v 0.32

Table of contents

- 1 Definición
- 2 Computación
- 3 Algoritmos Matriciales
- 4 Ritz Values

Valores Propios

Definición

Definición

Sea A una matriz cuadrada en $\mathbb{R}^{n \times n}$.

Diremos que $\lambda \in \mathbb{C}$ y $\mathbf{v} \in \mathbb{C}^n$ son valor y vector propios si:

$$A\mathbf{v} = \lambda\mathbf{v} \text{ y } \mathbf{v} \neq \mathbf{0}$$

¿Cómo podemos organizar todos los valores propios?

Sea A una matriz cuadrada en $\mathbb{R}^{n \times n}$. Diremos que $\lambda_i \in \mathbb{C}$ y $\mathbf{v}_i \in \mathbb{C}^n$ son el i -ésimo valor y vector propio. Si ahora los sumamos todos y los ordenamos considerando que el sub índice i corresponde a la i -ésima columna, obtenemos (Hint: $A\mathbf{v}_i = \lambda_i\mathbf{v}_i = \mathbf{v}_i\lambda_i$):

Valores Propios

Representación Matricial

¿Cómo podemos organizar todos los valores propios?

Sea A una matriz cuadrada en $\mathbb{R}^{n \times n}$. Diremos que $\lambda_i \in \mathbb{C}$ y $\mathbf{v}_i \in \mathbb{C}^n$ son el i -ésimo valor y vector propio. Si ahora los sumamos todos y los ordenamos considerando que el sub índice i corresponde a la i -ésima columna, obtenemos (Hint: $A\mathbf{v}_i = \lambda_i\mathbf{v}_i = \mathbf{v}_i\lambda_i$):

$$A \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_n \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_n \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix}$$
$$A V = V \Lambda$$

Valores Propios

Representación Matricial

¿Cómo podemos organizar todos los valores propios?

Sea A una matriz cuadrada en $\mathbb{R}^{n \times n}$. Diremos que $\lambda_i \in \mathbb{C}$ y $\mathbf{v}_i \in \mathbb{C}^n$ son el i -ésimo valor y vector propio. Si ahora los sumamos todos y los ordenamos considerando que el sub índice i corresponde a la i -ésima columna, obtenemos (Hint: $A\mathbf{v}_i = \lambda_i\mathbf{v}_i = \mathbf{v}_i\lambda_i$):

$$A V = V \Lambda$$

Si V^{-1} existe, se tiene:

$$A = V \Lambda V^{-1}$$

Valores Propios

Potencias de A

Dado $A = V \Lambda V^{-1}$, ¿Qué podemos decir de A^n ?

$$\begin{aligned} A^n &= (V \Lambda V^{-1})^n \\ &= V \Lambda V^{-1} V \Lambda V^{-1} \dots V \Lambda V^{-1} \end{aligned}$$

¿Podemos simplificar algo?

$$A^n = V \Lambda^n V^{-1}$$

¡Excelente!

Valores Propios

Otra definición

Un valor propio dominante...

Sea A una matriz cuadrada en $\mathbb{R}^{n \times n}$. Un *valor propio dominante* de A es un valor propio λ de magnitud ($|\lambda|$) mayor a todos los otros valores propios. Si existiera, el vector propio \mathbf{v} asociado a λ es llamado vector propio dominante.

Valores Propios

Primer Algoritmo

Un valor propio dominante...se encuentra así

Algorithm 1 Power Iteration

```
1:  $\mathbf{x}_0$ =Dato inicial
2: for  $j = 1$  to  $\infty$  do
3:    $\mathbf{u}_{j-1} = \mathbf{x}_{j-1} / \|\mathbf{x}_{j-1}\|_2$ 
4:    $\mathbf{x}_j = A \mathbf{u}_{j-1}$ 
5:    $\lambda_j = \mathbf{u}_{j-1}^T A \mathbf{u}_{j-1}$ 
6: end for
7:  $\mathbf{u}_j = \mathbf{x}_j / \|\mathbf{x}_j\|_2$ 
```

Valores Propios

Convergencia de Power Iteration

Th: Sea A una matriz de $n \times n$ con valores propios $\lambda_1, \dots, \lambda_n$, y $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$. Asuma que los vectores propios forman una base de \mathbb{R}^n . Para casi todo vector inicial, Power Iteration converge *linealmente* al vector propio asociado a λ_1 con tasa de convergencia $S = |\lambda_2/\lambda_1| < 1$.

Valores Propios

Demostración

Sea $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ una base de \mathbb{R}^n y $\lambda_1, \dots, \lambda_n$ los valores propios de A con $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ los vectores propios asociados a cada valor propio.

Dado que \mathbf{v}_i forman una base de \mathbb{R}^n , podemos escribir cualquier vector en \mathbb{R}^n como:

$$\mathbf{x}_0 = \sum_{i=1}^n c_i \mathbf{v}_i = V \mathbf{c}.$$

Además considere que $c_1 \neq 0$ y $c_2 \neq 0$. Aplicando el Power Iteration y recordando que $AV = V\Lambda$ obtenemos:

$$\mathbf{x}_0 = V \mathbf{c}$$

$$A \mathbf{x}_0 = A V \mathbf{c} = V \Lambda \mathbf{c}$$

$$A^2 \mathbf{x}_0 = A V \Lambda \mathbf{c} = V \Lambda^2 \mathbf{c}$$

$$\vdots$$

$$A^k \mathbf{x}_0 = V \Lambda^k \mathbf{c}$$

Valores Propios

Demostración - Continuación

Si normalizamos en cada iteración obtenemos:

$$\begin{aligned}\frac{A^k \mathbf{x}_0}{\lambda_1^k} &= \frac{V \Lambda^k \mathbf{c}}{\lambda_1^k} \\ &= \sum_{i=1}^n c_i \left(\frac{\lambda_i}{\lambda_1} \right)^k \mathbf{v}_i\end{aligned}$$

Donde obtenemos $\left(\frac{\lambda_i}{\lambda_1} \right)^k \rightarrow 0$ como $k \rightarrow \infty$ para $i \geq 2$.

Valores Propios

¿Y de que sirve esto?

Conclusión Power Iteration

- Ahora tenemos un algoritmo para encontrar el valor propio dominante.
- ¿Y si quiero encontrar otro?
- Este algoritmo no sirve. O si...
- Pensemos....
- Aplicaciones: "PCA, Page-Rank, Graph Theory, Google, Facebook, Netflix, ..."

Valores Propios

¡Otra definición!

Más propiedades de valores propios

Th: Sea $\lambda_1, \dots, \lambda_n$ los valores propios de A .

- (a) Los valores propios de la matriz inversa A^{-1} son $\lambda_1^{-1}, \dots, \lambda_n^{-1}$,
asumiendo que A^{-1} existe.
- (b) Los valores propios de la matriz $A - sI$ son: $\lambda_1 - s, \dots, \lambda_n - s$.

En ambos casos los vectores propios son los mismos. La demostración de estas propiedades se vieron anteriormente.

Valores Propios

Flashback

¿Y que ocurre si utilizamos el Power Iteration con la matriz inversa?

- ¿Se puede?
- No creo....
- Veamos.

Valores Propios

Utilizando A^{-1} donde aparece A y considerando

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \cdots > |\lambda_n|$$

```
1:  $\mathbf{x}_0$ =Dato inicial
2: for  $j = 1$  to  $\infty$  do
3:    $\mathbf{u}_{j-1} = \mathbf{x}_{j-1} / \|\mathbf{x}_{j-1}\|_2$ 
4:    $\mathbf{x}_j = A^{-1} \mathbf{u}_{j-1}$ 
5:    $\lambda_j = \mathbf{u}_{j-1}^T A^{-1} \mathbf{u}_{j-1}$ 
6: end for
7:  $\mathbf{u}_j = \mathbf{x}_j / \|\mathbf{x}_j\|_2$ 
```

Obviando los pasos, podemos concluir que obtenemos λ_n^{-1} y \mathbf{v}_n . Una sustitución interesante es reemplazar la línea 5 por $\lambda_j = \mathbf{u}_{j-1}^T \mathbf{x}_j$

Valores Propios

¡Aprovechando el momentum!

Utilizando $A - sI$ donde aparece A y considerando
 $|\lambda_1| > |\lambda_2| > |\lambda_3| > \dots > |\lambda_n|$

```
1:  $\mathbf{x}_0$ =Dato inicial
2: for  $j = 1$  to  $\infty$  do
3:    $\mathbf{u}_{j-1} = \mathbf{x}_{j-1} / \|\mathbf{x}_{j-1}\|_2$ 
4:    $\mathbf{x}_j = (A - sI)^{-1} \mathbf{u}_{j-1}$ 
5:    $\lambda_j = \mathbf{u}_{j-1}^T \mathbf{x}_j$ 
6: end for
7:  $\mathbf{u}_j = \mathbf{x}_j / \|\mathbf{x}_j\|_2$ 
```

Obviando los pasos, podemos concluir que obtenemos $\tilde{\lambda}$ y $\tilde{\mathbf{v}}$.

¿Qué es $\tilde{\lambda}$? No entiendo...

- Anteriormente dijimos que la aplicación del algoritmo Power Iteration a la matriz A encontraba el valor propio dominante λ_1 de esta.
- OK, ya se eso.
- ¿Que ocurre si aplicamos el Power Iteration a la matriz A^{-1} ?
- Encontramos λ_n^{-1} dado que λ_n^{-1} es el *valor propio dominante* de A^{-1} . :-)
- ¿Y?
- mmmm, pensemos.
- Si aplicamos el algoritmo Power Iteration a $(A - sI)^{-1}$ encontramos ... ¡El valor propio dominante de $(A - sI)^{-1}$!

Valores Propios

¿Qué es $\tilde{\lambda}^{-1}$? No entiendo...

- Si aplicamos el algoritmo Power Iteration a $(A - sI)^{-1}$ encontramos ... ¡El valor propio dominante de $(A - sI)^{-1}$!
- OK, entonces $\tilde{\lambda}$ es el valor propio dominante de $(A - sI)^{-1}$.
- ¿Es $\tilde{\lambda}$ un valor propio de A ?
- No
- Pff, ¿Y de que me sirve?
- ¡De mucho! Con $\tilde{\lambda}$ podemos encontrar un valor propio diferente al valor propio dominante o el de menor magnitud (en el caso de usar A^{-1}).
- ¿Cómo?
- $\tilde{\lambda} = (\lambda_i - s)^{-1}$. Simplificando: $\lambda_i = \tilde{\lambda}^{-1} + s$.

Valores Propios

Segundo Algoritmo

Un valor propio *no* dominante...se encuentra así

Algorithm 2 Inverse Power Iteration

```
1:  $\mathbf{x}_0$ =Dato inicial
2: for  $j = 1$  to  $\infty$  do
3:    $\mathbf{u}_{j-1} = \mathbf{x}_{j-1} / \|\mathbf{x}_{j-1}\|_2$ 
4:    $\mathbf{x}_j = (\mathbf{A} - s \mathbf{I})^{-1} \mathbf{u}_{j-1}$ 
5:    $\lambda_j = \mathbf{u}_{j-1}^T \mathbf{x}_j$ 
6: end for
7:  $\mathbf{u}_j = \mathbf{x}_j / \|\mathbf{x}_j\|_2$ 
```

Este algoritmo encuentra $\lambda_i = \tilde{\lambda}^{-1} + s$. Donde λ_i es el valor propio más cercano a s .

Valores Propios

Tercer Algoritmo

Otro algoritmo — Rayleigh Quotient Iteration

Algorithm 3 Rayleigh Quotient Iteration

```
1:  $\mathbf{x}_0$ =Dato inicial
2: for  $j = 1$  to  $\infty$  do
3:    $\mathbf{u}_{j-1} = \mathbf{x}_{j-1} / \|\mathbf{x}_{j-1}\|_2$ 
4:    $\lambda_{j-1} = \mathbf{u}_{j-1}^T \mathbf{A} \mathbf{u}_{j-1}$ 
5:   Solve  $(\mathbf{A} - \lambda_{j-1} \mathbf{I}) \mathbf{x}_j = \mathbf{u}_{j-1}$ 
6: end for
7:  $\mathbf{u}_j = \mathbf{x}_j / \|\mathbf{x}_j\|_2$ 
```

(Para valores propios no repetidos) Este algoritmo encuentra el valor propio dominante λ_i y converge cuadráticamente. ¡Si la matriz es simétrica converge cúbicamente!.

Valores Propios

Uff, hemos visto muchas cosas...

Conclusiones

- Power Iteration: Valor propio dominante
- Inverse Power Iteration: Valor propio más cercano a s .
- Rayleigh Quotient Iteration: Depende de la condición inicial y converge cuadráticamente.
- Rayleigh Quotient Iteration: (Precaución línea 5) ¡Resolver $(A - \lambda_{j-1} I) \mathbf{x}_j = \mathbf{u}_{j-1}$ únicamente si la matriz no es singular!
- ¿Qué hago si la matriz $(A - \lambda_{j-1} I)$ es singular?
- Detener el algoritmo, ¡ya se convergió! :-)
- Esto es como jugar con fuego ... ¡pero sin quemarse!

Valores Propios

Sigamos...

¿Recuerda?

Si A tiene valor propio λ y vector propio \mathbf{v}
entonces $B = Q^{-1}AQ$, tiene valor propio λ y vector propio $Q^{-1}\mathbf{v}$.

En este caso se dice que A es *una matriz similar a B*.

Theorem

Matrices Similares tienen los mismos valores propios.

Otra Demostración:

$$\begin{aligned}\det(B - \lambda I) &= \det(Q^{-1}AQ - \lambda I) \\ &= \det(Q^{-1}AQ - \lambda Q^{-1}IQ) \\ &= \det(Q^{-1}(A - \lambda I)Q) = \det(Q^{-1})\det(A - \lambda I)\det(Q) \\ &= \det(A - \lambda I)\end{aligned}$$

Valores Propios

Algoritmos matriciales para encontrar todos los valores propios al mismo tiempo

Normalized Simultaneous Iteration

```
1:  $\bar{Q}_0 = I$   
2: for  $j = 0$  to  $\infty$  do  
3:    $A \bar{Q}_j = \bar{Q}_{j+1} R_{j+1}$   
4: end for  
5:  $\Lambda = \text{diag}(\bar{Q}^T A \bar{Q})$ 
```

Valores Propios

Algoritmos matriciales para encontrar todos los valores propios al mismo tiempo

Unshifted QR algorithm

```
1:  $Q_0 = I$ 
2:  $R_0 = A$ 
3:  $\bar{Q} = Q_0$ 
4: for  $j = 0$  to  $\infty$  do
5:    $Q_{j+1} R_{j+1} = qr(R_j Q_j)$ 
6:    $\bar{Q} = \bar{Q} Q_j$ 
7: end for
8:  $\Lambda = \text{diag}(R Q)$ 
```

Recuerde que $A = QR \Rightarrow Q^T A Q = RQ$, i.e. A es similar a RQ .

¡En este caso tenemos una secuencia de transformaciones similares!

Valores Propios

Por último, Ritz values...

¿Qué son los Ritz values?

- Son una *estimación* de los valores propios.
- ¿Cómo se obtienen?
- Se obtienen de la matriz H_n de la iteración de Arnoldi en GMRes.
- ¿Qué es H_n ? En GMRes se construye \tilde{H}_n .
- $H_n = Q_n^* Q_{n+1} \tilde{H}_n$, i.e. removiendo la última fila de \tilde{H}_n .
- Ahora tengo una matriz más pequeña, ¿Cómo la uso?
- Se obtienen los valores propios de esta (¡Estos son los Ritz Values!) a través de los métodos ya discutidos :-)
- ¿Puedo hacer shifts y el resto de cosas que aprendí? ¡Sí!

¿Algo más?

- Sí
- ¿Que cosa?
- Les sugiero encarecidamente que busquen en el libro un ejemplo de cada método y lo hagan a mano en lo posible.
- OK, ¿Algo más?
- Sí
- Uff, ¿No será mucho?
- No. Implementen todos los métodos y traigan sus códigos a clases en su computador personal.
- OK, that's easy.
- Excellent!